Mühendislik İstatistiğinden Makine Öğrenmesine

Montgomery & Runger, *Applied Statistics and Probability for Engineers* (6. baskı) kitabındaki formüllerin ML'de nerede, hangi algoritmik problemde işe yaradığı.

Nasıl okunur. Her blokta sırayla formül, ne dediği, ML'de nerede kullanıldığı ve sayısal bir örnek var. Bölüm numaraları (ör. **7-3.5**) kitaptaki konumu gösterir. Örneklerdeki sayılar ya tek tek hesaplanmış aritmetik ya da bu rehber için çalıştırdığım simülasyonlardır; gerçek bir projeden alınmış veri değildir.

Kitapta olan / olmayan. ★ **uzantı** işaretli satırlar kitaptaki formülün ML'ye bağlanması ya da türetilmiş halidir; kitapta bu şekilde yazmaz (ör. Ridge = Gauss prior). İşaretsiz olanlar kitaptaki içeriğe dayanır. Kitap bir mühendislik istatistiği kitabı: gradient descent, SVD/eigen ayrışımı ve entropi/KL burada yok (son sayfada nereden bakılacağı yazıyor).



ML yaşam döngüsü ve her aşamada kullanacağın formül aileleri

Öncelik sırası (vaktin kısıtlıysa): ① Bölüm 3 (bias–variance) ve 2 (MLE/MAP), ② Bölüm 5–6 (regresyon, PRESS, VIF), ③ Bölüm 4 (ensemble varyansı), ④ Bölüm 7–8 (güven aralığı, A/B, model karşılaştırma), ⑤ Bölüm 9–10 (DOE ve izleme).

1 Veri ön analizi ve Bayes teoremi

Kitap: 2-7 · 6-4 · 6-7

$$P(A \mid B) = \frac{P(B \mid A)\,P(A)}{P(B)}$$

$$P(C \mid x_1, \ldots, x_n) \propto P(C) \prod_{i=1}^{n} P(x_i \mid C)$$

$$[\,Q_1 - 1.5\,IQR,\;\; Q_3 + 1.5\,IQR\,]$$

Ne diyor

Bayes teoremi, elindeki kanıtla (pozitif tahmin) gerçek durumun olasılığını ters çevirir. IQR aralığı ise box plot'taki (6-4) uç değer kuralıdır: bu aralığın dışındaki noktalar aday outlier'dır.

ML'de nerede

- **Naive Bayes sınıflandırıcı:** Bayes formülüne özellikler arası koşullu bağımsızlık varsayımı eklenince algoritmanın kendisi çıkar (spam, metin sınıflandırma).
- **Precision/recall yorumu:** Nadir sınıfta yüksek recall, düşük precision demek olabilir. Aşağıdaki sayı bunu gösteriyor.
- **Temizlik:** IQR kuralı hızlı bir ilk filtre. Regresyon artıklarının normalliğine bakmak için olasılık grafiği (6-7) kullanılır.

Örnek. Sınıf oranı %0,1, modelin recall'u %99, yanlış pozitif oranı %1 olsun. Pozitif dediği bir örneğin gerçekten pozitif olma olasılığı 0,99·0,001 / (0,99·0,001 + 0,01·0,999) = **%9.0**. Yani tahmin "pozitif" dediğinde on kişiden dokuzu yanlış alarm. Fraud ve anomali projelerinde accuracy yerine precision–recall ile bu hesabı birlikte okumak gerekir.

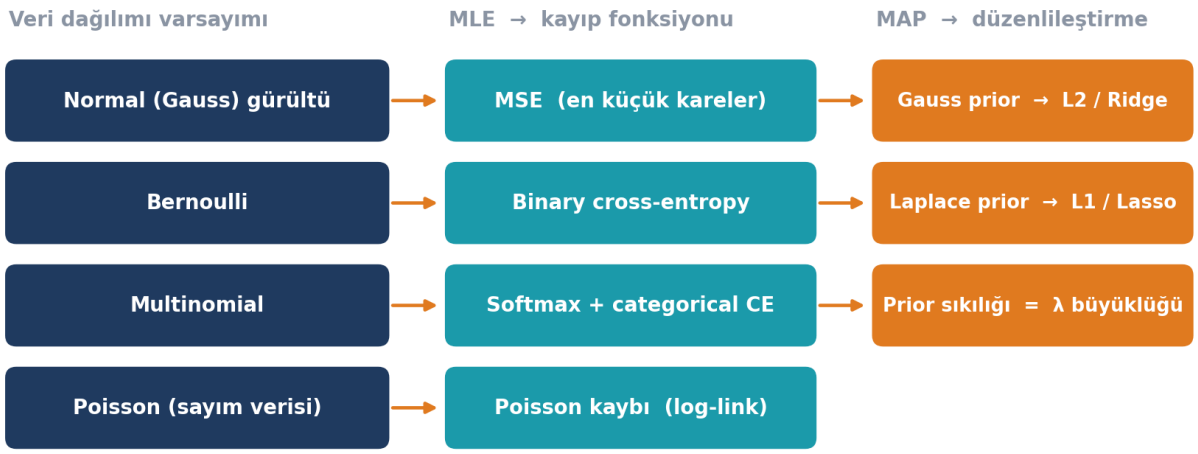
```
q1, q3 = np.percentile(x, [25, 75]);  iqr = q3 - q1
outlier = (x < q1 - 1.5 * iqr) | (x > q3 + 1.5 * iqr)
scipy.stats.probplot(residuals, dist="norm", plot=plt)   # 6-7: artıklar normal mi?
```

2 Dağılım varsayımı → kayıp fonksiyonu

Kitap: Bölüm 3–4 · 7-4.2 · 7-4.3

$$\hat{\theta} = \arg\max_{\theta} \sum_{i=1}^{n} \ln f(x_i;\theta)$$

$$\hat{\theta}_{MAP} = \arg\max_{\theta} \left[\sum_{i} \ln f(x_i;\theta) + \ln p(\theta) \right]$$



Her kayıp fonksiyonu gizli bir dağılım varsayımıdır

Ne diyor

Maximum likelihood (7-4.2), verinin en olası olduğu parametreyi seçer. Gürültünün Gauss olduğunu varsayarsan log-likelihood'un negatifi $(y-\hat{y})^2$ ile orantılı çıkar; yani MSE. Bernoulli varsayarsan binary cross-entropy çıkar. Bayesian tahmin (7-4.3) buna bir prior ekler.

ML'de nerede

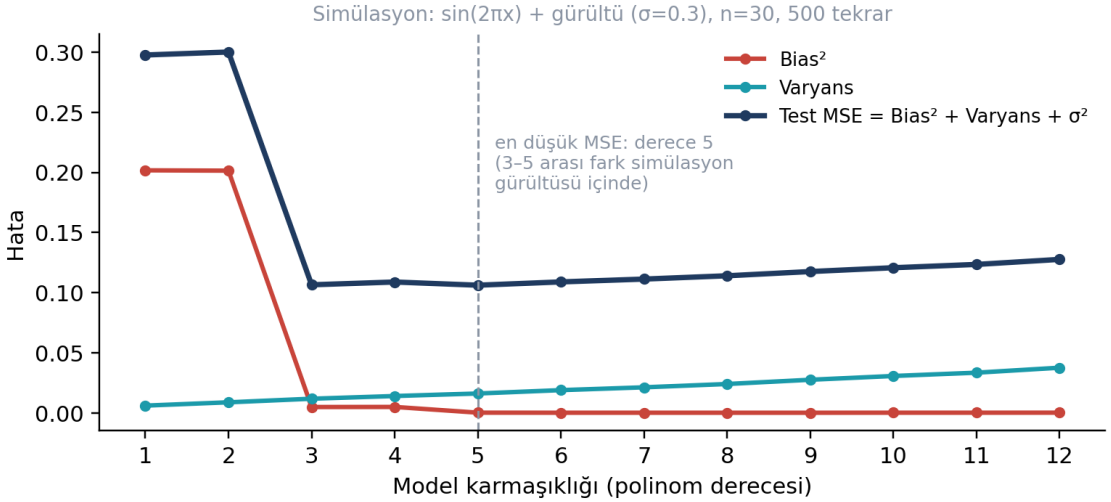
- **Loss seçimi:** "Hangi loss'u kullanmalıyım?" sorusunun ilk hali "verim hangi dağılımdan geliyor?". Sayım verisi (günlük sipariş, tıklama) için Poisson, ikili sonuç için Bernoulli.
- **Regularization:** Gauss prior L2'ye (Ridge), Laplace prior L1'e (Lasso) denk gelir. ★ **uzantı** Kitap 7-4.3'te Bayesian tahmini verir; bu eşleşmeyi kurmaz.
- **Sağa çarpık veri:** Lognormal dağılım (4-11) latency, fiyat, gelir gibi değişkenlerde log-dönüşümün gerekçesidir.
- **Ömür / churn:** Exponential (4-8) ve Weibull (4-10) "ne zaman ayrılır / ne zaman bozulur" modellerinin temelidir.

- **Bayesian A/B ve bandit:** Beta dağılımı (4-12) dönüşüm oranı üzerindeki belirsizliği taşır; Thompson sampling bunun üstüne kurulur.

3 Bias–variance dengesi

Kitap: 7-3.5

$$\mathrm{MSE}(\hat{\Theta}) = \mathrm{Var}(\hat{\Theta}) + \left[\mathrm{Bias}(\hat{\Theta})\right]^2$$



Sabit 30 noktalı tasarımda polinom derecesi arttıkça bias düşer, varyans artar

Ne diyor

Bir tahmin edicinin hatası iki parçadır: sistematik sapma (bias) ve örnekten örneğe oynama (varyans). Karmaşıklığı artırmak biri düşürürken diğerini yükseltir. Simülasyonda derece 1→2 hiçbir şey kazandırmıyor (sin fonksiyonu 0,5 etrafında tek simetrik), derece 3'te bias çöküyor, sonrasında varyans yavaşça yükseliyor. Bu kurulumda 3–5 arası fark simülasyon gürültüsü içinde; aşırı uyumun etkisi n=30'da hafif kalıyor.

ML'de nerede

- Regularization gücü (λ, weight decay), ağaç derinliği, kNN'de k, nöral ağda genişlik ve epoch sayısı (early stopping) aynı dengenin ayar düğmeleridir.
- Train hatası düşük, validation hatası yüksekse varyans problemi; ikisi de yüksekse bias problemi. Çare farklıdır: birinde veri/regularization, diğerinde daha zengin model.

4 Kovaryans ve ensemble varyansı

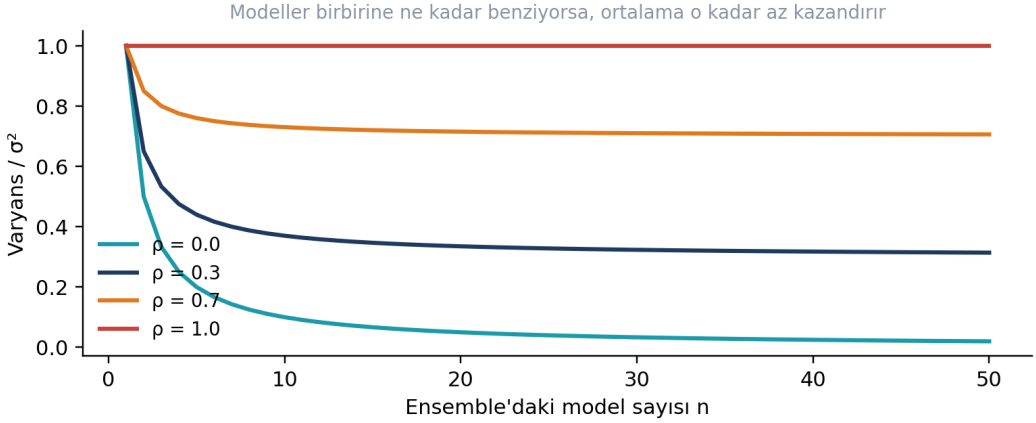
Kitap: 5-2 · 5-3.2 · 5-4 · 7-2

$$\mathrm{Cov}(X,Y) = E[XY] - \mu_X\mu_Y, \qquad \rho_{XY} = \frac{\mathrm{Cov}(X,Y)}{\sigma_X\sigma_Y}$$

$$\mathrm{Var}(aX+bY) = a^2\sigma_X^2 + b^2\sigma_Y^2 + 2ab\,\mathrm{Cov}(X,Y)$$

$$\mathrm{Var}(\bar{f}) = \sigma^2\left[\rho + \frac{1-\rho}{n}\right]$$

$$SE(\bar{X}) = \frac{\sigma}{\sqrt{n}} \;\Rightarrow\; \text{gradyan gürültüsü} \propto \frac{1}{\sqrt{B}}$$



n model ortalaması: modeller ne kadar korelasyonluysa kazanç o kadar küçük

Ne diyor

Toplamın varyansı, kovaryans terimini de içerir (5-4). Eşit varyanslı ve ρ korelasyonlu n modelin ortalamasında varyans σ²[ρ + (1−ρ)/n] olur. ★ **uzantı** Bu türetme 5-4'ün doğrudan sonucu ama kitapta ensemble diye geçmez. n büyüse bile varyans ρσ² tabanının altına inmez.

ML'de nerede

- **Random Forest:** Her bölünmede rastgele özellik alt kümesi seçmenin sebebi ρ'yu düşürmektir. Ağaç sayısını artırmak tek başına 1/n kısmını küçültür, ρσ² kısmına dokunmaz.
- **Bagging / model ortalaması:** Farklı algoritmalardan gelen modeller, aynı algoritmanın farklı seed'lerinden daha düşük ρ verir.
- **PCA ve Mahalanobis:** Kovaryans matrisi PCA'nın girdisidir (eigen ayrışımı kitapta yok). İki değişkenli normal dağılım (5-3.2) Mahalanobis mesafesiyle anomali tespitinin ve Gaussian mixture'ların zeminidir.
- **Mini-batch gürültüsü:** Ortalamanın standart hatası σ/√n (7-2), batch büyüdükçe gradyan gürültüsünün 1/√B ile azaldığını verir. ★ **uzantı**

5 Regresyon ve lojistik regresyon

Kitap: 12-1.3 · 11-10 · 12-6.1 · 12-6.2

$$\hat{\beta} = (\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T\mathbf{y}$$

$$p(x) = \frac{1}{1+e^{-(\beta_0+\beta_1 x)}}, \qquad \text{odds ratio} = e^{\beta_1}$$

Ne diyor

Normal denklemler lineer regresyonun kapalı form çözümüdür. Lojistik regresyon (11-10) olasılığı sigmoid ile modeller; katsayının üstel değeri, x bir birim arttığında odds'un kaç kat değiştiğini söyler.

ML'de nerede

- **Neden gradient descent?** X^TX tersi d özellik için yaklaşık O(d³). Özellik sayısı büyüdükçe iteratif yöntem kazanır.
- **Lojistik regresyon = nöral ağın son katmanı.** Sigmoid + binary cross-entropy tam bu modeldir. Odds ratio ise modeli iş tarafına açıklarken en kolay yorumlanan çıktıdır.
- **One-hot encoding (12-6.2):** k kategori için k−1 gösterge değişkeni; hepsini koyarsan sabit terimle doğrusal bağımlı olur (dummy variable tuzağı).
- **Polinom özellikler (12-6.1):** Derece arttıkça eğitim hatası hep düşer, doğru ölçü validation/PRESS olmalı (Bölüm 6).

```
beta = np.linalg.solve(X.T @ X, X.T @ y)      # ters almak yerine solve; ya da np.linalg.lstsq
odds_ratio = np.exp(beta[1])                  # lojistikte: x bir birim artınca odds kaç kat
```

6 Model teşhisi: PRESS, Cook, VIF

Kitap: 12-5.2 · 12-6.3 · 12-6.4

$$\mathbf{H} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T, \qquad \hat{\mathbf{y}} = \mathbf{H}\mathbf{y}$$

$$\text{PRESS} = \sum_{i=1}^{n}\left(\frac{e_i}{1-h_{ii}}\right)^2$$

$$D_i = \frac{r_i^2}{p}\cdot\frac{h_{ii}}{1-h_{ii}}, \qquad r_i = \frac{e_i}{\sqrt{\hat{\sigma}^2(1-h_{ii})}}$$

$$\text{VIF}_j = \frac{1}{1-R_j^2}$$

$$C_p = \frac{SS_E(p)}{\hat{\sigma}^2} - n + 2p, \qquad R^2_{adj} = 1 - \frac{SS_E/(n-p)}{SS_T/(n-1)}$$

Ne diyor

Hat matrisinin köşegeni h_{ii}, her noktanın kendi tahminini ne kadar çektiğini (leverage) verir. PRESS, her noktayı dışarıda bırakıp modeli yeniden kurarak yapılan tahmin hatasıdır (12-6.3); tek bir fit ile hesaplanır. Cook mesafesi (12-5.2) bir noktanın modeli ne kadar oynattığını, VIF (12-6.4) bir özelliğin diğerleriyle ne kadar örtüştüğünü ölçer.

Doğrulama (bu rehber için çalıştırdım)

Yöntem	PRESS	Maliyet
Hat matrisi kapalı formu	222.167352	1 fit
Elle 200 kez yeniden fit (leave-one-out)	222.167352	200 fit
sklearn LeaveOneOut + LinearRegression	222.167352	200 fit

Sentetik veri: n=200, 5 parametre (sabit dahil). Üç yöntem aynı sonucu veriyor.

ML'de nerede

- **Ucuz LOOCV:** Lineer (en küçük kareler) modellerde çapraz doğrulama hatasını yeniden eğitmeden alırsın. Ridge için de benzer bir kapalı form vardır, ama kitapta yok.
- **Veri temizleme:** Kitaptaki eşikler: $h_{ii} > 2p/n$ yüksek leverage, $D_i > 1$ etkili gözlem. Outlier'dan farkı, modeli gerçekten bozan noktayı seçmesi.
- **Çoklu doğrusallık:** VIF 1'den büyükse örtüşme başlamıştır. Kitap, VIF > 10'u sorun sayan yazarları aktarır; bazıları bunu fazla gevşek bulup sınırı 4–5 önerir. Çare: birini at, birleştir ya da Ridge kullan. ★ **uzantı** (Ridge kitapta yok)
- **Özellik alt kümesi seçimi:** $C_p \approx p$ olan ve düzeltilmiş R^2 yüksek modeller tercih edilir; özellik ekledikçe sahte iyileşmeyi cezalandırırlar.

Dürüst not. PRESS'in tek fit ile hesaplanması yalnızca en küçük kareler modelleri için geçerli. Ağaç, nöral ağ ve benzeri modellerde bu kısayol yok.

```
H = X @ np.linalg.pinv(X.T @ X) @ X.T
e = y - H @ y
press = np.sum((e / (1 - np.diag(H)))**2)     # n kez fit yerine 1 kez
vif_j = 1 / (1 - r2_of_x_j_on_other_features)
```

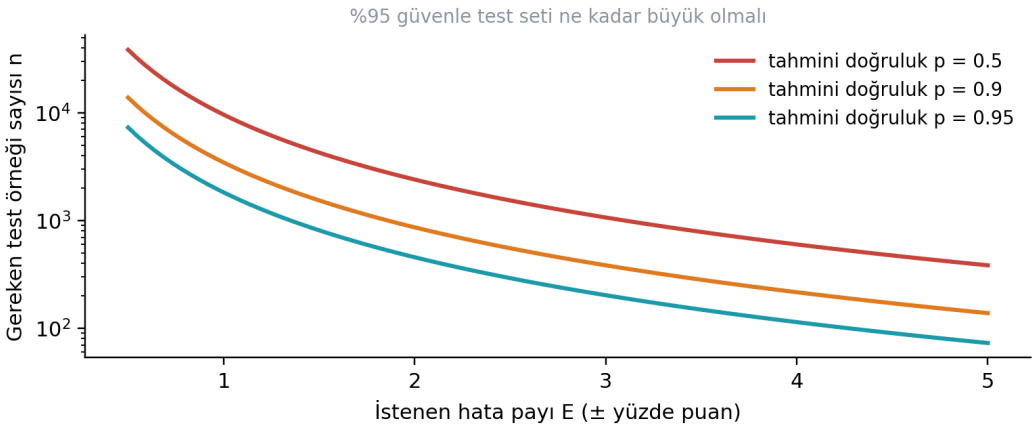
7 Değerlendirmenin belirsizliği

Kitap: 8-4 · 7-3.4 · 8.6 · 8-7 · 12-4

$$\hat{p} \pm z_{\alpha/2}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

$$n = \left(\frac{z_{\alpha/2}}{E}\right)^2 p(1-p)$$

$$\hat{y}_0 \pm t_{\alpha/2,\, n-p}\sqrt{\hat{\sigma}^2\left(1 + \mathbf{x}_0^T(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{x}_0\right)}$$



İstenen hassasiyete göre gereken test örneği sayısı

Ne diyor

Bir metriğin tek bir sayı olarak raporlanması eksiktir. Oran için güven aralığı (8-4) ve tersi olan örneklem büyüklüğü formülü, "test setim yeterince büyük mü?" sorusunu cevaplar. Tahmin aralığı (8-7, 12-4) ise tek bir yeni tahminin etrafındaki bandı verir.

Sayısal örnek

- 1000 örnekli test setinde doğruluk %92 ise %95 güven aralığı yaklaşık **%90.3 – %93.7**.
- ±1 puan hassasiyet için en kötü durumda (p=0,5) yaklaşık **9604** örnek gerekir. Doğruluk 0,92 civarındaysa **2827** yeter.

ML'de nerede

- **Model raporu:** "%92" yerine "%92 (±1,7)" yazmak, iki modelin farkının gürültü mü sinyal mi olduğunu görünür kılar.
- **Bootstrap (7-3.4, 8.6):** Formülü olmayan metrikler (F1, AUC) için güven aralığı: veriden iadeli örnekle, metriği tekrar hesapla, yüzdelik dilimlerine bak. Bagging'in de temeli bu.
- **Müşteriye belirsizlik:** Regresyon tahminine "120, %95 aralık 95–145" demek ürün tarafında tek sayıdan çok daha değerli.

Dürüst not. Oran için normal yaklaşımı, gözlenen başarı ve başarısızlık sayıları yeterince büyükken güvenilir (kaba kural: ikisi de en az 10). Çok küçük ya da çok uçtaki oranlarda başka yöntem gerekir.

```
rng = np.random.default_rng(0)
idx = [rng.integers(0, n, n) for _ in range(2000)]
boot = [metric(y[i], pred[i]) for i in idx]
lo, hi = np.percentile(boot, [2.5, 97.5])
```

8 Model karşılaştırma, A/B testi, drift

Kitap: 10-4 · 10-6 · 9-7 · 9-8 · 9-9.2 · 9-10

$$t_0 = \frac{\bar{d}}{s_d/\sqrt{n}}, \qquad d_i = \text{acc}_{A,i} - \text{acc}_{B,i}$$

$$z_0 = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1-\hat{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

$$n = \frac{\left[z_{\alpha/2}\sqrt{(p_1+p_2)(q_1+q_2)/2} + z_\beta\sqrt{p_1q_1 + p_2q_2}\right]^2}{(p_1 - p_2)^2}$$

$$\chi_0^2 = \sum_i \frac{(O_i - E_i)^2}{E_i}, \qquad E_{ij} = \frac{(\text{satır}_i)(\text{sütun}_j)}{n}$$

Ne diyor

"B modeli gerçekten daha mı iyi, yoksa şans mı?" sorusu bir hipotez testidir. Aynı fold'larda ölçülen iki modelin farkı için paired t-testi (10-4), üretimde iki grubun dönüşüm oranı için iki oran testi (10-6), eğitim ve canlı veri dağılımı için ki-kare (9-7, 9-8).

Sayısal örnekler

- **Paired t (örnek 10-fold doğruluklar):** ortalama fark 0.0067, s_d = 0.00183, t_0 = 11.59, p ≈ 1e-06.
- **Drift (ki-kare):** Cihaz tipi için eğitimde beklenen [1200, 600, 200], canlıda gözlenen [1080, 640, 280]. χ^2 = 46.67; serbestlik derecesi 2 için %5 kritik değer 5.99. Dağılım kaymış (p ≈ 7e-11).

A/B testi: kaç kullanıcı gerekir? (α=0,05 iki yönlü, güç %80, formül 10-6.2)

Baz dönüşüm	Hedef	Grup başına gereken örnek
%10	%10.5	≈ 57.763
%10	%11.0	≈ 14.751
%10	%12.0	≈ 3.841
%10	%13.0	≈ 1.774

ML'de nerede

- **Yeni model canlıya çıkar mı?** Küçük iyileşmeyi ölçmek çok örnek ister: baz oran %10 iken +0,5 puanı görmek için grup başına on binlerce kullanıcı gerekir.
- **Drift tespiti:** Kategorik özelliklerde ki-kare ile eğitim–canlı karşılaştırması. sklearn'ün `chi2` özellik seçici fonksiyonu aynı istatistiğin negatif olmayan özellikler için bir uyarlaması; 9-8'deki tablo testinin birebir kopyası değil.
- **Küçük model yeterli mi?** Distill edilmiş modelin ana modelden "anlamlı fark yok" ile değil, belirlediğin tolerans içinde olduğunu kanıtlamak için equivalence testi (9-10) doğru araç.
- **Birden çok veri seti / çok sayıda test:** Wilcoxon signed-rank (9-9.2) dağılım varsaymaz; p-değerlerini birleştirme (9-11) ve çoklu karşılaştırma mantığı (13-2.3) yanlış pozitifi sınırlar.

Dürüst not. Paired t-testi fold farklarının bağımsız olduğunu varsayar. K-fold'da eğitim setleri örtüştüğü için bu varsayım tam sağlanmaz ve p-değeri olduğundan iyimser çıkar. Yukarıdaki p ≈ 1e-6 bu yüzden "kesin üstün" değil, "güçlü işaret" olarak okunmalı; farklı seed'lerle tekrar ya da düzeltilmiş t-testi güvenceyi artırır.

9 Hiperparametre ayarı için deney tasarımı

Kitap: 14-5 · 14-7 · 14-8 · 13-2 · 13-4

Ne diyor

Her hiperparametreye iki seviye (düşük/yüksek) verip bütün kombinasyonları denemek 2^k deneme ister. Kesirli faktöriyel (14-7) bunun bir kesrini seçer: 4 hiperparametre için tam tasarım 16 deneme, yarım kesir $2^{4-1} = 8$ deneme. Bir faktörün etkisi, o faktör "+" iken ortalama sonuç eksi "−" iken ortalama sonuçtur.

Deneme	A: öğrenme hızı	B: batch	C: dropout	D = ABC: weight decay
1	−	−	−	−
2	+	−	−	+
3	−	+	−	+
4	+	+	−	−
5	−	−	+	+
6	+	−	+	−
7	−	+	+	−
8	+	+	+	+

2^{4-1} yarım kesir, tanımlayıcı ilişki I = ABCD. Örnek seviyeler: A = 1e-4 / 1e-3, B = 32 / 128, C = 0,1 / 0,4, D = 0 / 1e-2.

ML'de nerede

- **Keşif aşaması:** 7 hiperparametre için $2^{7-3} = 16$ denemeyle hangilerinin ve hangi etkileşimlerin önemli olduğunu ayıklayıp, sonra yalnızca onlar üstünde ince arama yaparsın.
- **Alias yapısı:** Bu yarım kesirde ana etkiler üçlü etkileşimlerle (A ≡ BCD), ikili etkileşimler birbirleriyle (AB ≡ CD, AC ≡ BD, AD ≡ BC) karışır. Yani AB etkisi görünürse bunun AB mi CD mi olduğunu bu tasarım ayırt edemez.
- **Yanıt yüzeyi (14-8):** Önemli birkaç faktör bulunduktan sonra ikinci dereceden bir yüzey uydurup optimuma doğru ilerlemek, Bayesian optimizasyonun klasik atasıdır.
- **Blok tasarım (13-4):** Seed'i ya da veri bölmesini blok olarak ele alırsan, onun gürültüsünü model etkisinden ayırırsın.

Dürüst not. İki seviyeli tasarımlar yanıtın aralık boyunca kabaca monoton olduğunu varsayar. Kırılgan, çok tepeli hiperparametre yüzeylerinde iki seviye yanıltabilir; bu yüzden keşif için iyi, son ayar için Bayesian optimizasyon veya rastgele arama ile birleştirilmeli.

```
import itertools, numpy as np
runs = [(a, b, c, a*b*c) for a, b, c in itertools.product([-1, 1], repeat=3)]   # D = ABC
effect = lambda j: y[[r[j] == 1 for r in runs]].mean() - y[[r[j] == -1 for r in runs]].mean()
```

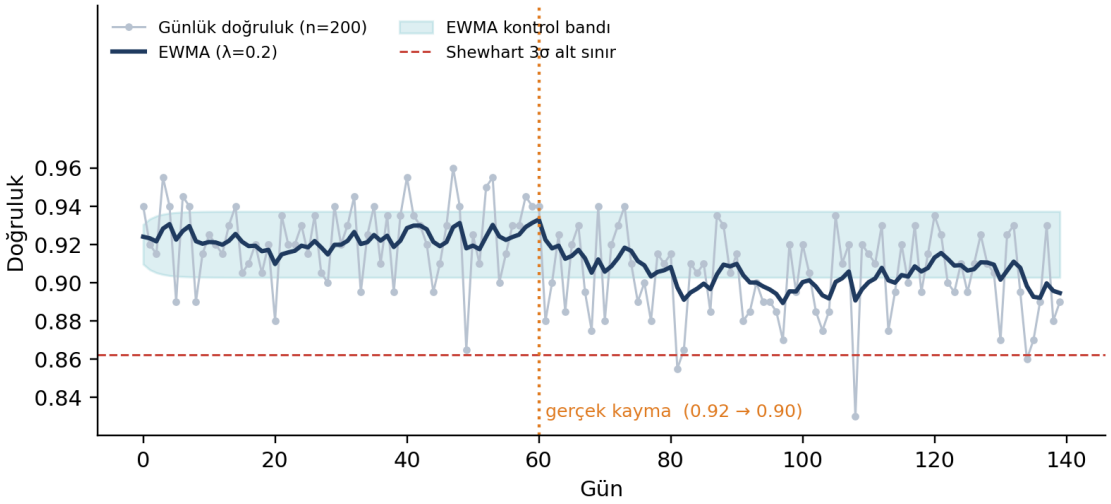
10 Canlıda izleme: EWMA ve CUSUM

Kitap: 15-2 · 15-8.1 · 15-8.2

$$z_t = \lambda x_t + (1-\lambda) z_{t-1}, \quad \text{UCL/LCL} = \mu_0 \pm L\sigma\sqrt{\frac{\lambda}{2-\lambda}\left[1-(1-\lambda)^{2t}\right]}$$

$$C_t^+ = \max\left[0,\ x_t - (\mu_0 + K) + C_{t-1}^+\right], \quad C_t^- = \max\left[0,\ (\mu_0 - K) - x_t + C_{t-1}^-\right]$$

$$m_t = \beta_1 m_{t-1} + (1-\beta_1)\, g_t \quad \Longleftrightarrow \quad \lambda = 1-\beta_1$$



Tek örnek akış: doğruluk 60. günde 0,92'den 0,90'a kayıyor

Ne diyor

Üretimdeki model sürekli ölçülen bir süreçtir. Shewhart kartı (15-2) her noktayı tek tek 3σ ile sınar, küçük kaymaları geç yakalar. EWMA ve CUSUM (15-8) geçmişi biriktirdiği için küçük ve kalıcı kaymalara duyarlıdır.

Simülasyon sonucu (2000 tekrar)

Yöntem	Kayma sonrası 80 günde yakalama	Ortanca gecikme (gün)	Kayma öncesi 60 günde yanlış alarm
Shewhart 3σ	%97	16	%17.2
EWMA	%100	7	%23.5
CUSUM	%100	8	%11.7

Kurulum: günlük 200 tahmin, temel doğruluk 0,92, kayma 0,92→0,90 (yaklaşık 1σ). EWMA λ=0,2 ve L=2,7; CUSUM k=0,5σ ve h=5σ.

Sonucu nasıl okumalı

- EWMA ve CUSUM bu kaymayı Shewhart'tan yaklaşık iki kat hızlı yakalıyor (ortanca 7–8 gün, Shewhart 16 gün).
- Ama bedelsiz değil: L=2,7 ile EWMA bu kurulumda Shewhart'tan **daha fazla** yanlış alarm veriyor. Bu bir ayar meselesi; L'yi büyütmek yanlış alarmı düşürür, gecikmeyi artırır. Bu koşulda CUSUM hem hızlı hem daha az yanlış alarmlıydı.
- Sınırları tahmin ettiğin gibi değil, hedef bir yanlış alarm süresine (ARL) göre kalibre et. Sonuçlar bu tek senaryoya ait, başka kayma büyüklüğünde sıralama değişebilir.

ML'de nerede

- **Model performans izleme:** Günlük doğruluk, precision veya hata oranını kontrol kartına koy; sınır aşılınca yeniden eğitim alarmı.

- **Optimizer'lar:** Adam'daki momentum terimi ve BatchNorm'daki running mean bir EWMA'dır ($\lambda = 1-\beta_1$). Eğitim loss'unu yumuşatmak da aynı formül. ★ **uzantı**
- **Etiket gecikmesi:** Gerçek etiket haftalar sonra geliyorsa doğruluğu izleyemezsin; girdi dağılımı (Bölüm 8, ki-kare) ve tahmin skor dağılımı üzerinde aynı kartları kullan.

11 Maliyete duyarlı karar eşiği

Kitap: 15-10

$$\text{pozitif de eğer} \quad p > \frac{C_{FP}}{C_{FP} + C_{FN}}$$

Ne diyor

Karar teorisi (15-10) beklenen maliyeti en küçük yapan eylemi seçmeyi anlatır. İki eylemli sınıflandırmada bu, $p \cdot C_{FN} > (1-p) \cdot C_{FP}$ olduğunda pozitif demeye iner. ★ **uzantı** Eşik formülü bu özel durumun türetmesi, kitapta bu haliyle yok.

C_FN / C_FP	Eşik (olasılık)
1	0.500
2	0.333
5	0.167
10	0.091
20	0.048

ML'de nerede

- Yanlış negatif yanlış pozitiften 10 kat pahalıysa eşiği 0,5'te bırakmak yanlıştır; 0,09 civarına inmelisin (fraud, hastalık taraması, arıza tahmini).
- Bu eşik yalnızca **kalibre** olasılıklarda geçerli. Skorlar kalibre değilse önce kalibrasyon (Platt, isotonic) gerekir; bunlar kitapta yok.
- Kitaptaki minimax kriteri, maliyetleri veya olasılıkları bilmediğinde en kötü durumu en aza indiren seçimi verir.

```
r = C_fn / C_fp
y_pred = (proba > 1 / (1 + r)).astype(int)     # proba: kalibre olasılık
```

12 Kitapta olmayanlar ve nereden bakılır

Tamamlayıcı kaynaklar

Eksik konu	Nereden
Gradient descent, optimizasyon, sayısal kararlılık	Goodfellow, *Deep Learning*: Bölüm 4 ve 8
SVD, eigen ayrışımı (PCA'nın matematiği)	Goodfellow: Bölüm 2 · Strang, *Linear Algebra*
Entropi, KL divergence, cross-entropy türetmesi	Goodfellow: Bölüm 3 · Bishop, *PRML*: 1.6
Ridge, Lasso, elastic net'in teorisi	Hastie et al., *ESL*: Bölüm 3 · Goodfellow: Bölüm 7
Çapraz doğrulama ve model seçimi teorisi	Hastie et al., *ESL*: Bölüm 7

13 Hızlı başvuru tablosu

Tek bakışta

Formül / kavram	ML'deki karşılığı	Kitap
Bayes teoremi	Naive Bayes, precision/recall yorumu	2-7
MLE	MSE, cross-entropy, Poisson loss	7-4.2
Bayesian tahmin (MAP)	L1/L2 regularization ★ **uzantı**	7-4.3
MSE = Var + Bias²	Overfit/underfit, karmaşıklık seçimi	7-3.5
Var(aX+bY), kovaryans	Ensemble, Random Forest, PCA girdisi ★ **uzantı**	5-2, 5-4
Normal denklemler	Lineer regresyon; GD'ye neden ihtiyaç	12-1.3
Lojistik regresyon, odds ratio	Sınıflandırma, NN son katmanı	11-10
PRESS, hat matrisi	Tek fit ile LOOCV (lineer modeller)	12-6.3
Cook mesafesi, leverage	Etkili nokta temizliği	12-5.2
VIF	Çoklu doğrusallık, Ridge gerekçesi	12-6.4
Oran güven aralığı, n formülü	Test seti boyutu, metrik ± hata payı	8-4
Bootstrap	Her metrik için belirsizlik, bagging	7-3.4, 8.6
Paired t / Wilcoxon	İki modeli aynı fold'larda karşılaştırma	10-4, 9-9.2
İki oran testi, n formülü	Üretimde A/B testi	10-6
Ki-kare (uyum, tablo)	Drift tespiti, kategorik özellik testi	9-7, 9-8
2^{k-p} tasarım, yanıt yüzeyi	Hiperparametre keşfi ve ayarı	14-5, 14-7, 14-8
EWMA, CUSUM	Model izleme; Adam/BatchNorm ortalaması	15-8
Karar teorisi	Maliyete duyarlı eşik ★ **uzantı**	15-10